

忆枢 MemNexus 面向军事作战智能体的可追溯长短期记忆系统

成员：张晋菡、程星桦、李林原、赵英浩

一、研究背景

军事作战智能体在多轮交互中持续接收任务要求、背景材料、过程记录和用户修正。这些信息具有不同的适用范围与保存期限，且会随任务推进发生变化。面向持续协作的记忆系统，需要在有限上下文中维持任务连续性，并为跨会话使用提供稳定的信息依据。

信息的使用周期决定了长短期记忆的分工。当前目标、待办和临时格式构成会话内的工作状态，项目约定、稳定偏好和重要事件则具有持续保存价值。通过分别管理两类信息，系统能够在延续当前任务的同时，按范围调用此前积累的知识。

有限上下文与持续增长的交互历史之间存在容量约束。完整历史包含重复表达、无关细节和过时内容，直接输入会增加处理开销；固定截取近期消息又容易遗漏早期约定。因此，记忆形成需要结合语义压缩与结构化保存，在压缩对话的同时保留关键事实、适用条件和原始依据。

记忆的长期使用还依赖明确的组织结构与更新规则。主题概览需要关联具体事实，事实变更需要区分现实变化、错误纠正和待确

认冲突。检索过程则应结合相关性、作用范围和有效时间选择证据，使回答能够反映当前适用状态，并支持对历史依据的追溯。

忆枢 MemNexus 据此构建可追溯的长短期记忆系统，贯通信息形成、分层组织、动态演化与按需检索。系统作为上层智能体的记忆服务，提供信息保存、更新、查询和来源回查能力。项目以军事作战智能体为应用背景，现阶段通过通用记忆流程与模拟推演材料验证方案。

二、相关工作

2.1 长短期记忆与大模型摘要

MemGPT 借鉴操作系统的分层存储思想，将有限上下文与外部记忆分开管理，并通过函数调用调入所需信息。该思路为长短期记忆的容量分配与协同访问提供了参考。MemoChat 利用结构化备忘组织历史对话，将记忆整理、检索和回复连接为循环流程，以支持长程交互中的内容一致性。^{[1][2]}

SimpleMem 从信息密度出发，提出语义结构化压缩、在线语义整合和意图感知检索规划。其第三版利用大模型筛选对话中的有效信息，明确指代与时间，并形成可独立理解的记忆单元。查询阶段结合语义、词法和符号索引，按问题需求调整检索范围与深度。^[3]本项目参考其信息提炼与检索规划思路，将摘要压缩、事实保存和来源关联纳入同一记忆形成过程。

2.2 长期记忆的层级组织

H-MEM 按语义抽象程度，将记忆划分为领域、类别、记忆线索和具体片段四层。上层提供概括与索引，底层保存具体内容，检索过程通过层间索引逐步选择相关分支。^[4]这种组织方式将主题理解与事实定位连接起来。本项目据此设计长期记忆的层级结构，并通过事实版本与来源关系维护上层概览。层级组织带来的检索收益需要结合具体检索路径评价。

2.3 动态更新与冲突处理

Zep 通过时间知识图谱管理持续变化的信息，分别记录事实的有效时间与系统记录时间。对于有效时间重叠的矛盾关系，系统识别受影响记录并更新失效时间，同时保留历史状态。^[5]该方法为记忆的时间建模与历史追溯提供了参考。本项目进一步区分现实变化、错误纠正和待确认冲突，使更新操作与信息关系相对应，并以来源证据和适用语境作为判断依据。

2.4 结构化查询与按需检索

ChatDB 将数据库作为符号记忆，通过结构化操作支持精确存取。MIRIX 提供向量、BM25 和字符串匹配等检索工具，并根据上下文选择检索方式。^{[6][7]}精确字段匹配与语义相关性检索由此形成互补。本项目结合问题所需信息、时间条件和上下文预算选择检索通道，并在需要时并发召回候选。

上述研究分别提供了信息压缩、层级组织、时间建模与检索规划的设计依据。忆枢将这些方法纳入统一的记忆生命周期，以事实版本和来源关系连接各处理阶段。研究重点是协调信息完整性、更新一致性与运行开销，使形成的记忆能够持续维护、按需使用并追溯依据。

三、研究目标

3.1 当前任务与跨会话信息的连续性

系统以长短期协同管理维持交互连续性。短期记忆保存当前目标、计划、待办和近期交互，长期记忆保存具有持续价值的事实、偏好和项目约定。两类记忆在各自的保存周期内更新，并共同为当前问题提供上下文。

信息的保存与调用依据作用范围确定。临时要求随适用会话维护，稳定信息经来源核验后进入长期管理。跨会话访问通过项目与用户范围选择相关记录，并引用已有事实版本构建本轮上下文。该设计使任务状态与长期知识保持关联，同时维持各自的更新边界。

3.2 记忆的可追溯性与动态一致性

系统以来源、作用范围、有效时间和版本描述记忆的适用条件。事实候选经过来源核验后进入正式管理，更新操作保留版本关系与审计记录。用户能够从回答定位所用事实，再回查原始材料，为核对和修正提供依据。

摘要与事实之间建立明确的依赖关系。摘要负责提供概览，事实支持精确查询和独立更新，长期概览记录所引用的事实版本。底层信息变化时，系统识别受影响的摘要并安排重建，使上层表达与当前有效记录保持一致。

3.3 检索适应性与运行效率

系统根据问题复杂度分配检索与生成资源。明确查值问题优先采用精确路径，综合问题通过互补通道获取证据。候选规模同时受信息需求和上下文预算约束，以协调证据覆盖与调用成本。方案评价综合考察答案适用性、检索耗时、模型调用量和维护开销。

运行架构通过状态记录与恢复机制支持持续服务。抽取失败、并发修改和请求取消均需要明确的处理边界，工作台则提供各阶段的状态与来源查看入口。模块划分围绕记忆形成、维护和使用展开，使原型具备可检查、可恢复的运行能力。

四、总体方案设计

4.1 总体架构

忆枢采用记忆服务与交互工作台相分离的架构。记忆服务集中管理信息形成、长期维护、检索和来源记录，工作台承担会话交互、记忆浏览、候选审阅和结果核对。上层智能体通过接口调用记忆能力，系统组成与职责见表 1。

总体架构以记忆维护和在线回答两条路径组织处理过程，如图 1 所示。维护路径将原始输入转化为可管理的记忆，并持续更新版本、索引和摘要。回答路径根据问题组织查询，选择适用证据并生成结果。两条路径共享正式记录及其来源关系，共同遵守权限、作用范围和有效时间约束。




图 1 系统总体架构图

大模型承担上下文理解、摘要整理、关系判断建议和答案生成，记忆服务负责格式校验、来源核验与版本控制。对话与已录入文本作为原始输入，模型候选通过约束检查后进入正式记忆。该分工将语义处理与数据状态管理衔接起来。

表 1 系统组成

组成部分	主要职责	主要内容
交互工作台	接收问题，展示结果与依据	会话、记忆列表、来源窗口
运行编排	协调查询与处理流程	查询计划、检索选择、执行状态
短期记忆工作区	维护当前任务	近期交互、滚动摘要、目标和待办
长期记忆工作区	管理持久信息并查找证据	分组、对象属性、摘要和索引
记忆维护模块	形成候选并处理更新	来源检查、冲突判断、版本操作
数据存储	保存正式记录和操作历史	原始事件、事实版本、审计记录

4.2 长短期记忆的分工与组织

短期记忆以有界上下文窗口为基础，由近期交互、滚动摘要和任务状态共同组成。近期交互保留表达细节，滚动摘要衔接前文语境，任务状态维护目标、计划和待办。窗口容量依据任务需求与运行预算配置，使当前工作区保持适当规模。

长期记忆从整理结果中保留具有持续使用价值的信息，包括稳定偏好、项目规则和重要事件。保存依据是信息的持续性、来源与作用范围，已保存记录可以独立于当前对话窗口存在。每条记录关联有效时间和来源证据，并按照用户、项目或会话范围控制访问。

长期内容采用领域、类别、线索与事实版本的层级结构。领域和类别组织主题，线索关联具体事项，事实版本保存可独立更新的内容。上层概览通过引用关系连接底层事实，为项目浏览、事实定位和摘要维护提供统一结构。

4.3 记忆维护流程

记忆维护以原始事件为起点，依次完成增量整理、来源核验和关系判定。整理结果包括滚动摘要、任务状态和事实候选。通过校验的候选与已有记录比较后，依据重复、补充、变化、纠错或待确认冲突选择相应操作。原始事件、事实版本与操作记录共同保存更新依据。

正式记录的变化通过依赖关系传递至索引和摘要。即时维护完成当前回答所需的状态更新，周期维护承担摘要重建等可延后处理

的工作。各阶段保留处理进度与失败状态，使中断后的任务能够从已确认的位置继续执行。

在线回答与只读检索具有明确的职责边界。回答流程先整理当前会话中的待处理输入，再使用更新后的记忆组织证据；只读检索直接查询已有记录。两类入口分别服务于持续交互和独立查询，使记忆更新由明确的操作触发。

4.4 在线回答流程

在线回答由查询计划驱动。计划提取信息需求、关键词、主体属性和时间条件，再据此确定记忆层与检索通道。系统优先检查短期证据，并根据问题范围和证据充分性补充长期记忆。选定记忆层后，词法、符号与语义通道按条件执行召回。

召回候选经过适用性检查和版本去重后，按上下文预算组成回答依据。生成结果与实际采用的来源快照共同保存，返回前再次核验相关记录状态。该流程将检索时的证据选择与返回时的一致性检查连接起来，以处理生成期间发生的记忆变更。

五、关键机制与创新设计

5.1 大模型摘要与结构化事实协同形成

记忆形成需要同时保留对话语境与可独立管理的事实。连续交互中的目标、限制和补充说明分散在多次表达中，大模型能够结合上下文整合这些内容。忆枢据此设计摘要与结构化事实协同形成机

制，将语义压缩结果组织为不同用途的记忆表示，并通过原始来源建立关联。

一次整理同时形成滚动摘要、任务状态和事实候选。滚动摘要概括当前工作的背景与进展，任务状态明确目标、计划和待办，事实候选保存需要精确检索或独立更新的信息。三类表示分别服务于语境理解、任务延续和事实管理，并在同一整理过程中保持内容衔接。

事实候选以原子事实为基本单元，包含主体、属性、值、有效时间、作用范围和来源。复合表达根据属性与用途拆分后，各项内容可以分别维护。例如，“本次回答以表格形式呈现，行动代号为银河”包含输出格式和行动名称两项信息。前者作为会话要求保存，后者依据来源与保存规则确定是否进入长期记忆。




图 2 结构化抽取与长短期协同

图 2 展示了上述表示与长短期记忆之间的协同关系。临时信息进入当前工作区，具有持续价值的信息按规则纳入长期管理，事实

与原文通过来源关系连接。整理采用增量窗口，以新增事件为处理对象，并引入适量已处理内容补充语境。窗口同时受事件数量与输入长度约束，以控制单次整理成本。

增量处理通过进度记录区分新增依据与历史语境。每条新候选都需要关联本批新增事件，历史内容用于补全指代、时间和前后关系。积压输入按批推进，滚动摘要与任务状态保持长度上限。该机制使处理量随新增信息增长，并为后续检索和生成保留上下文空间。

来源校验决定候选进入正式记忆的条件。系统核对来源事件、原文引文、新增依据和作用范围，并结合表达性质判定信息状态。用户明确陈述或经核验的观察可作为事实依据，问句、假设和推断按其原有性质保留。助手回复中的事实需要追溯至有效来源，待确认内容经审核后再按规则管理。

形成过程通过输出校验和进度保存支持异常恢复。格式异常的模型结果在既定时间预算内修复，仍未通过校验的输入保留为待处理状态。原有记忆在本批处理完成前保持有效，原始事件与整理结果分别保存。后续核对能够据此定位抽取偏差，并从对应输入重新整理。

5.2 长期记忆分层组织与摘要维护

长期记忆通过层级组织连接项目概览与事实细节。领域划分主题，类别组织主题内的信息，线索关联具体事项，底层事实版本记

录精确内容及其来源。表 2 给出了各层职责。用户可以沿主题结构浏览内容，也可以围绕主体与属性定位具体记录。

表 2 长期记忆组织

组织层次	作用	示意内容
领域	划分较大的主题	项目管理
类别	区分主题中的内容	交付安排、输出要求
线索	关联具体事项	报告提交、简报格式
事实版本	保存取值、有效时间与来源	当前日期、历史日期及各自来源

层级分类依据已有领域、类别和线索信息建立，并可结合事实类型、主体和属性组织内容。应用中的既有分类也可作为标签，例如按“我情”“敌情”或“兵力部署”划分主题。分类负责组织语义位置，事实版本负责保存具体取值，两者通过关联关系共同支持概览与查询。

长期分组摘要以已保存事实为依据，概括组内内容及其联系。短期滚动摘要随近期交互更新，长期分组摘要随底层事实变化维护，二者分别服务于会话进展和持久知识概览。明确摘要的输入来源与更新条件，有助于保持不同层次记忆的一致性。

分组摘要采用带来源的概览表示。系统可根据已有事实形成基本概览，并在模型可用时生成自然语言综合摘要。每份摘要记录所引用的事实版本、实际覆盖数量与组内总数量，使读者能够了解概括范围。摘要维护在批量与时间预算内执行，以控制持续整理的开销。

事实版本与摘要之间的依赖关系用于确定更新范围。底层事实变化后，依赖旧版本的摘要失效，并依据当前记录重建。例如，交

付日期调整会触发相关概览更新；来源集合保持有效的摘要则可继续复用。该机制将局部事实变化传递至上层表达，同时减少重复整理。

同一对象的互补属性通过聚合视图集中展示，各属性分别保留来源与版本。日期、语言要求等属性可以独立修改，撤回操作也作用于对应记录。存在冲突时，视图保留各项差异及其依据，供后续关系判定与人工审阅使用。

层级浏览、属性聚合与来源回查共同构成长期记忆的组织方案。当前原型已将层级标签用于检索，完整的逐层索引路由列入后续扩展。对该结构的评价需要分别考察概览理解、事实定位和维护成本，以确定组织方式带来的实际收益。

5.3 基于信息关系的记忆演化

记忆演化以新旧信息的关系作为更新依据。系统先根据主体、属性和作用范围建立可比较的记录集合，再结合取值、表达性质与有效时间判定关系。可比较性检查明确了冲突判断的对象，为后续版本操作提供条件。

关系类型与维护操作建立对应关系。重复内容合并来源，互补属性分别保存，同一属性的不同取值则进一步区分现实变化、错误纠正和待确认冲突。模型提供语义关系建议，记忆服务依据证据、权限和版本状态执行更新，使关系判断与状态变更相互衔接。

现实变化通过有效时间区间表达前后状态。旧值在此前阶段适用，新值从明确时点开始生效。例如，报告日期由十五日调整为二十日，系统结束旧版本的有效区间并保存新版本。当前查询选用新值，历史查询依据指定时间返回相应安排。

错误纠正通过撤回关系标记原记录失实。用户说明此前日期记录有误时，系统保留错误版本与更正依据，并将修正后的内容纳入有效事实。被撤回记录用于解释修正过程，历史事实查询则依据有效状态筛选记录。这样可以分别表达“安排发生变化”与“原先记载有误”。

证据不足的差异进入待确认状态。系统保留当前有效记录，并集中展示候选与原记录之间的差异、来源和适用条件。用户据此作出确认后，再执行对应的演化操作。待确认队列将自动处理的边界显式化，其维护需要兼顾错误更新风险与审阅负担。




图3 记忆演化与摘要维护

图 3 展示了信息关系判定、版本演化与摘要维护之间的联系。作用范围用于协调长期规则和局部例外，例如项目采用三栏简报、本次会话临时采用段落形式。两项要求分别保存在对应范围内，当前回答依据会话条件选取，后续会话继续引用项目规则。范围约束由此参与更新判断和证据选择。

时间信息分别建模为记录时间、有效时间和内容中的日期属性。记录时间描述信息进入系统的时点，有效时间限定事实适用区间，日期属性表达截止日期等具体取值。各类时间按其语义参与更新与检索，缺失值按既定规则保留或处理。明确这些含义是解释当前状态与历史状态的基础。

版本变化通过依赖关系触发摘要、索引和生成缓存的检查。历史回答保留生成时的来源快照，新回答依据当前适用记录组织证据。内容版本与状态修订共同约束并发操作，使更新在对应记录状态上执行。

上述机制将语义关系、时间区间和版本状态纳入同一演化过程，支持变化记录、错误撤回与冲突审阅。连续追溯修订、迟到信息和多来源差异构成后续验证重点，用于检验复杂更新条件下的状态一致性。

5.4 自适应动态检索

自适应检索依据问题需求组织记忆访问与通道选择。词法检索匹配名称和关键词，符号检索定位主体与属性，语义检索补充含义相近

的表达。忆枢通过查询计划协调三类方法，并结合证据充分性与运行预算确定访问范围。图 4 给出了从查询分析到证据选择的处理关系。




图 4 三路自适应动态查询示意图

查询计划统一描述信息需求、关键词、主体属性和时间条件。通道选择直接使用这些字段，使问题理解与检索决策共享同一规划结果。模型规划与规则规划提供不同运行条件下的计划来源，格式校验和回退规则维持后续处理所需的结构。

记忆层访问采用短期优先、按需补充长期证据的顺序。对于当前单字段查询，取值唯一且符合条件的短期记录可直接提供依据。涉及历史状态、多个取值或综合信息需求时，系统进一步查询长期记忆。访问顺序与适用性判断共同决定证据范围，具体模式见表

3。

表 3 动态检索模式

问题与条件	检索模式
单字段查值且存在合格精确记录	优先采用词法与符号检索
概括、比较或多信息项查询	按可用条件选择通道，在同一记忆层内 并发召回
历史查询或指定时点查询	限定有效时间，再选择精确或互补检索 路径
规划字段缺少匹配记录	调整字段条件，持续执行权限、状态与 时间检查

选定记忆层后，各通道按照查询条件获取候选。词法通道使用全文索引与 BM25 排序评价关键词匹配程度，符号通道执行字段匹配，语义通道在向量服务可用时计算语义相关性。所有候选统一接受权限、作用范围、状态和有效时间检查，匹配分数用于合格记录之间的相关性排序。

互补通道在同一记忆层内并发执行，以重叠网络等待与本地计算。各通道独立召回，完成后按固定顺序融合，并依据记忆标识与内容版本去重。合并结果保留命中路径，便于解释候选来源。短期与长期记忆仍按既定顺序访问，以维持补充检索的条件关系。

一次检索共用时间预算和完成条件。通道异常会中止本次检索并记录错误，供调用方处理或重试。该约束明确了多通道结果的完成状态，使下游能够区分完整召回与执行失败。

动态 K 控制进入回答上下文的目标证据数量。系统依据所需信息项、检索深度和上下文预算确定 K ，再从合格候选中选择实际证据。实际数量同时受候选可用性与内容长度约束，证据不足时保留缺口。该设计将结果规模与问题需求关联起来。

多信息项查询在证据选择阶段兼顾各项需求。问题同时涉及格式与核验状态时，候选条件需要覆盖对应属性，融合结果也应保留不同信息项的依据。信息覆盖检查与相关性排序分别承担完整性和匹配度评价，为综合问题提供可检查的证据集合。

该方案通过条件选择减少简单查询的额外调用，并为复杂查询保留互补检索路径。

5.5 来源快照与结果复用

来源快照将回答内容绑定到生成时实际使用的证据。系统保存事实版本、原文片段和当时状态，并据此建立可回查的引用关系。用户能够从回答定位相应记忆与原始输入，核对结论的依据。引用编号由实际证据映射产生，其作用是标识来源关联。




图 5 回答与来源的对应关系机制示意图

图 5 展示了回答、来源快照与当前事实之间的关系。历史快照用于解释既有回答的生成依据，当前事实用于组织新的回答。后续

更正保留原快照，并改变相关记录的当前适用状态，使历史解释与当前查询分别依据对应时间的记录。

结果复用在生成条件一致时调用已有答案。复用条件包括上下文、模型、会话、来源版本和数据状态，相同的在途请求也可合并处理。缓存通过容量与有效期限限制管理保存规模，降低重复请求中的最终生成成本。

复用过程嵌入正常的权限检查、查询规划和检索流程。系统依据本次取得的证据判定复用条件，并在返回前复验来源有效性。记录撤回、到期或范围变化会使依赖旧状态的结果失效。来源快照负责保留历史依据，复用校验负责维持当前结果的适用性。

六、系统实现与结果验证

6.1 系统实现

原型通过交互工作台呈现记忆形成、维护和使用过程。会话区承载输入与回答，记忆区展示短期状态、长期分组和事实来源，观测区记录检索与生成阶段的执行信息。界面将操作结果与对应数据关联起来，支持对方案各环节的检查。

当前实现通过批量上限与时间预算控制记忆维护开销。增量整理每批最多处理 5 个新增存储轮次，并引入最多 15 个已处理轮次作为语境；实际输入还受长度预算约束。这里的轮次按存储记录计数，具体容量依据任务条件配置。长期摘要每次最多维护 8 组，每组最多使用 12 条事实。

6.1.1 工作台与短期记忆



工作台将会话输入、回答和短期记忆放在同一交互视图中。滚动摘要、目标与待办呈现当前任务状态，事实记录提供来源查看入口，便于检查本轮交互如何形成记忆。

6.1.2 短期记忆整理与长期记忆组织

短期

长期

检索

观测

短期记忆

0 条待整理事件

整理

大模型摘要

本次会话围绕蓝港软件测试桌面演练，用户提出本次临时约束：只处理12份合成文档、当前批次由周宁复核、验收要求为12份文档全部有来源编号；并要求结合项目长期规则输出简洁实施方案与任务指令卡（任务概述、分工表、执行阶段、三组任务卡，700字以内），区分项目规则与本次约束、引用记忆来源、未知信息标注待确认。

当前目标

产出蓝港软件测试桌面演练的简洁实施方案与任务指令卡（700字以内），包含任务概述、分工表、执行阶段与三组任务卡

计划与待办

区分项目长期规则与本次会话临时约束；引用记忆来源并标注待确认信息；按任务概述、分工表、执行阶段、三组任务卡结构编写；生成蓝港演练的实施方案与三组任务指令卡

结构化短期记忆

事实 会话作用域 stated 有效

本次蓝港软件测试桌面演练只处理12份合成文档。

▶ 1 条原文证据 · v1

1 条证据 审阅演化

事实 会话作用域 stated 有效

当前批次由周宁复核。

▶ 1 条原文证据 · v1

1 条证据 审阅演化

事实 会话作用域 stated 有效

本次验收要求为12份文档全部有来源编号。

▶ 1 条原文证据 · v1

1 条证据 审阅演化

事实 会话作用域 stated 有效

用户将12份文档数量、周宁复核、12份文档全部有来源编号三项声明为本次会话的临时约束。

短期

长期

检索

观测

H-MEM 长期组织

4 个对象 · 7 条属性事实

同一对象、同一作用域的补充信息整合为一条对象记忆。属性保留独立来源和版本，便于纠错；存在冲突的属性会单独标明。

▶ 分层摘要与记忆维护 0 个分组

蓝港演练

项目记忆

负责人：林悦；验收规则：每张任务指令卡必须包含负责人、输入、任务、完成条件与异常处理；资料规则：每项已知事实注明来源，缺失信息标注待确认；项目范围：仅验证软件工作流

▶ 4 条属性 · 查看来源与演化

蓝港演练的复核组

项目记忆

职责：检查任务结果

▶ 1 条属性 · 查看来源与演化

蓝港演练的记录组

项目记忆

职责：整理输入资料

▶ 1 条属性 · 查看来源与演化

蓝港演练的检索组

项目记忆

职责：核对记忆来源

▶ 1 条属性 · 查看来源与演化

短期整理视图展示从原始事件提取的事实及其状态，长期记忆视图按层级与对象属性组织持久内容。两类视图共同呈现信息从会话状态进入长期管理的过程。

6.1.3 作战方案与指令卡生成



执行阶段

- 准备：确认12份文档清单，标注来源编号规则（编号体例需确认）。
- 执行：逐份登记来源、编号，缺失标待确认。 7
- 复核：周宁复核当前批次。 8
- 验收：核验12份全部有来源编号。 2

三组任务卡

卡一 | 清单与编号组：输入12份合成文档；任务为建清单并赋来源编号；完成条件为12份均有草拟编号；异常为缺失来源→标待确认。**卡二 | 来源核对组：**输入已编号文档；任务为逐份核对来源；完成条件为核对记录齐全；异常为来源冲突→标记待澄清。**卡三 | 复核验收组：**负责人周宁；输入核对后文档；任务为复核当前批次并确认验收；完成条件为12份全部有来源编号；异常为编号缺失→退回补正。

五、任务指令卡

三卡均含负责人、输入、任务、完成条件、异常处理五字段，符合项目验收规则。 1

生成视图将记忆证据组织为方案草案与结构化任务卡，并保留回答中的来源关联。用户可结合引用核对关键内容与已保存记录。

6.1.4 检索执行



6.1.6 生成复用观测



复用观测视图展示生成请求的命中状态及相关执行信息。该视图用于检查复用条件与实际调用结果，支持对重复请求开销的分析。

6.2 结果验证

6.2.1 实验目的

实验围绕证据召回、结构化生成和重复请求开销评价系统。记忆召回检查任务材料中的关键事实，生成评价检查方案结构、字段覆盖与来源引用。复用测试固定规划器和上下文，记录不同缓存状态下的耗时与最终生成调用次数。各项评价分别对应信息供给、输出组织和运行效率。

6.2.2 数据集

实验采用 5 个虚构桌面推演想定，每个想定包含 36 条记忆卡，共 180 条。数据中长期记忆 155 条、短期记忆 25 条，用于形成跨会

话背景与当前约束共同参与的查询条件。各想定按照相同结构组织材料。

想定级信息包括任务目标、演练区域、边界、时间窗口、通信频道、主要风险和情景分案。单位级信息包含类型、位置、角色、装备和约束。输出要求规定指令卡字段及安全边界，使各组能够在一致任务条件下比较。

数据集将事实型记忆召回与结构化生成结合起来。长期记录提供稳定背景，短期记录提供当前条件，输出内容需要综合两类依据。评价范围限定于上述虚构材料中的记忆使用与文本生成表现。

6.2.3 实验分组

完整记忆组使用忆枢记忆库，先检索证据，再生成方案与指令卡。空记忆基线组使用相同问题，在未提供已保存记忆的条件下生成回答。两组对照用于观察记忆证据对事实覆盖、输出结构与引用表现的影响。

复用测试组固定规划器和上下文，依次测试禁用复用、首次请求未命中和后续请求命中三种状态。记录最终生成调用次数及响应耗时，用于评价生成条件一致时的复用收益。

6.2.4 评价指标

自动评分采用事实覆盖、方案结构、指令卡字段、证据引用和约束合规五项指标，综合得分按下式计算。

$$\begin{aligned} \text{综合得分} = & 0.35 \times \text{事实覆盖} + 0.20 \times \text{方案结构} + 0.25 \times \text{指令卡字段} \\ & + 0.1 \times \text{证据引用} + 0.1 \times \text{约束合规} \end{aligned}$$

事实覆盖评价输出对目标、区域、边界、频道、风险和单位信息的包含情况。该指标用于观察任务相关事实进入最终答案的程度。

方案结构评价输出是否包含方案名称、概述、部署、情景假设、任务指令卡和风险说明。它反映答案的组织完整性。

指令卡字段评价任务类型、目标、时间、装备、分配、协同、规则和执行要点等内容的覆盖情况。字段覆盖与单位覆盖共同用于计算该项得分。

证据引用评价输出是否包含有效来源引用，用于检查答案与记忆证据之间的关联。

约束合规评价输出是否满足虚构桌面推演的内容边界，并检查未知信息的处理方式。评价规则排除真实坐标、现实目标、武器用法和伤害性细节。

实验通过条件为综合得分达到 0.8，且证据引用与约束合规两项均满足要求。该判定同时考察内容覆盖、来源关联和输出边界，使形式完整性与证据质量共同参与评价。


6.2.5 实验结果

完整记忆组在 5 个想定中通过 4 个，空记忆基线组通过 0 个。两组平均综合得分分别为 0.8400 和 0.5733，事实覆盖均值分别为 0.6000 和 0.2381。在本组测试中，引入记忆证据对应更高的综合得分与事实覆盖。


两组指令卡字段覆盖均值均为 1.0000，说明相同生成模型在两种条件下均能组织完整字段。组间差异主要体现在任务事实与来源依据，字段齐全需要结合事实覆盖和引用结果共同解释。

完整记忆组端到端中位耗时为 18.571 秒，生成阶段中位耗时为 13.060 秒。复用测试经历禁用、未命中和连续 3 次命中，命中请求累计减少 3 次最终生成调用。对应请求耗时为 45 至 91 毫秒，该结果适用于本次固定规划器与相同上下文的测试条件。

6.2.6 结果可视化



图中比较了完整记忆组与空记忆基线的质量指标。完整记忆组在综合得分和事实覆盖上的优势，与两组相同的字段覆盖结果形成互补说明。评价需要同时关注内容依据与输出结构。



图中分别呈现端到端耗时、生成阶段耗时和复用请求耗时。首次生成包含规划、检索和模型生成成本，复用命中请求则使用已有生成结果。图示支持对本次重复请求收益的分析，收益范围由上下文一致性和来源有效性共同决定。



各想定的分项得分显示，方案结构、指令卡字段与引用输出相对稳定，事实覆盖仍有改善空间。该分布为后续排查信息项解析、证据选择和生成遗漏提供了依据。

6.2.7 结果分析

实验结果支持记忆证据参与任务生成的设计。完整记忆组能够将分散记录组织为生成上下文，并在当前 5 个想定中取得更高的事实覆盖与综合得分。该结果说明，结构化记忆与证据选择能够为具体任务内容提供依据。

引用输出使生成结果具备可回查的来源关联。用户可以根据引用核对相应记忆，进一步检查回答与输入材料之间的关系。引用指标评价的是来源关联情况，具体判断的正确性仍需结合原文核验。

复用测试表明，在生成条件一致且来源仍有效时，已有结果可以减少最终模型调用。3 次命中对应 3 次调用减少和 45 至 91 毫秒的请求耗时。该收益集中于满足精确复用条件的重复请求。

事实覆盖是当前结果中的主要改进点。部分想定存在区域边界、单位装备和风险字段遗漏，需要进一步区分检索遗漏与生成遗漏。后续评价应记录各信息项在查询计划、候选证据和最终答案中的覆盖情况，以定位损失环节。

评价结果还表明，完整字段与充分事实依据需要分别衡量。两组均达到完整字段覆盖，而事实覆盖和通过情况存在差异。因此，后续测试应继续结合来源引用、约束合规与事实覆盖，并扩大样本及任务类型。当前结论限于 5 个虚构想定和既定自动评分规则。

七、展望

后续研究将优先完善记忆状态与回答表达的一致性。现有复盘
中，部分回答将仍待确认的候选描述为已完成更新。改进将使成
功、待确认和失败等表达直接对应实际操作结果，并加强重复候选
管理，以控制人工审阅负担。

记忆形成与层级组织需要进一步开展独立评价。在相同模型和
预算下，对比原始窗口、普通摘要及带来源约束的摘要，考察事实
保留、条件遗漏、否定语义和错误引入。层级组织则围绕概览理
解、事实定位与维护开销设置对照，以分辨各设计环节的贡献。

动态演化将扩展至连续修订、迟到信息、多来源差异和临时例
外解除等情形。评价同时检查当前取值与历史解释，并记录待确认
项的处理过程。人工审阅界面需要清楚展示差异、依据与操作影
响，使复杂关系能够在明确条件下得到处理。

检索优化将结合真实向量服务与独立测试集推进。固定通道与
条件通道的比较需要同时记录证据覆盖、调用量和响应耗时，并考
察复杂问题中的信息完整性。多用户并发与数据规模变化也将纳入
目标环境测试，明确当前架构的容量边界。

规模扩展依据测得的主要开销选择优化方向。候选读取、向量
搜索和层级路由分别需要评估访问成本及召回效果，再确定索引与
存储方案。扩展后的组件继续遵守统一的权限、来源、时间和版本
约束，保持各处理阶段的数据一致性。

应用集成将完善资料管理、模板审阅和结果导出，并验证与目标宿主的连接。部署环节重点确认身份管理、数据保留与恢复流程。已有原型贯通了信息形成、维护、检索与来源回查，后续将围绕自动处理可靠性和真实使用收益继续验证。

八、参考文献

- [1] Packer et al. MemGPT: Towards LLMs as Operating Systems. 2023/2024. <https://arxiv.org/abs/2310.08560v2>
- [2] Lu et al. MemoChat: Tuning LLMs to Use Memos for Consistent Long-Range Open-Domain Conversation. 2023. <https://arxiv.org/abs/2308.08239v2>
- [3] Liu et al. SimpleMem: Efficient Lifelong Memory for LLM Agents. 2026. <https://arxiv.org/abs/2601.02553v3>
- [4] Sun and Zeng. Hierarchical Memory for High-Efficiency Long-Term Reasoning in LLM Agents. 2025. <https://arxiv.org/abs/2507.22925v1>
- [5] Rasmussen et al. Zep: A Temporal Knowledge Graph Architecture for Agent Memory. 2025. <https://arxiv.org/abs/2501.13956v1>
- [6] Hu et al. ChatDB: Augmenting LLMs with Databases as Their Symbolic Memory. 2023. <https://arxiv.org/abs/2306.03901v2>
- [7] Wang and Chen. MIRIX: Multi-Agent Memory System for LLM-Based Agents. 2025. <https://arxiv.org/abs/2507.07957v1>